

DDPM 相关数学原理的详细推导

摘要

去噪扩散概率模型 (Denoising Diffusion Probabilistic Models, DDPM) 的核心思想是：先定义一个逐步加噪的正向马尔可夫过程，将真实数据变成近似高斯噪声；再学习一个反向去噪过程，从噪声逐步恢复数据。本文专门讨论 DDPM 背后的数学原理，重点推导正向扩散闭式公式、反向后验分布、变分下界、KL 散度训练项以及噪声预测目标。为方便读者理解，文中会明确说明用到的基础公式，例如贝叶斯公式、高斯分布线性变换、高斯乘积公式与重参数化技巧。

1 符号约定

设真实数据为 $\mathbf{x}_0$ ，例如一张图像。真实数据分布记作：

$$\mathbf{x}_0 \sim q(\mathbf{x}_0).$$

DDPM 引入一系列隐变量：

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T,$$

其中 $\mathbf{x}_t$ 表示第 t 个时间步的带噪数据。一般来说， t 越大，噪声越强；当 $t = T$ 时， $\mathbf{x}_T$ 接近标准高斯噪声。

DDPM 有两个过程：

- 正向扩散过程 $q(\mathbf{x}_{1:T} | \mathbf{x}_0)$ ：从真实数据逐步加噪；
- 反向生成过程 $p_\theta(\mathbf{x}_{0:T})$ ：从噪声逐步去噪生成数据。

本文使用粗体 $\mathbf{x}$ 表示向量， $\mathbf{I}$ 表示单位矩阵， $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 表示均值为 $\boldsymbol{\mu}$ 、协方差为 $\boldsymbol{\Sigma}$ 的高斯分布。

2 需要用到的基础公式

2.1 贝叶斯公式

DDPM 的后验推导需要用到贝叶斯公式。对于随机变量 A 和 B ，有：

$$p(A | B) = \frac{p(B | A)p(A)}{p(B)}.$$

如果再加入条件变量 C ，则有条件形式：

$$p(A | B, C) = \frac{p(B | A, C)p(A | C)}{p(B | C)}.$$

在 DDPM 中，我们会用它推导：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}.$$

由于正向过程是马尔可夫链， $\mathbf{x}_t$ 在给定 $\mathbf{x}_{t-1}$ 后与 $\mathbf{x}_0$ 条件独立，因此：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

所以：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}.$$

2.2 高斯分布的线性变换

如果

$$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

并且

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{A}\mathbf{z},$$

那么

$$\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \mathbf{A}\mathbf{A}^\top).$$

特别地，如果 $\mathbf{A} = \sigma\mathbf{I}$ ，则：

$$\mathbf{x} = \boldsymbol{\mu} + \sigma\mathbf{z} \implies \mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2\mathbf{I}).$$

DDPM 中经常使用这种写法，把高斯采样写成：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

2.3 高斯乘积仍然正比于高斯

如果同一个变量 $\mathbf{x}$ 出现在两个高斯密度中：

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1, \sigma_1^2\mathbf{I})\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_2, \sigma_2^2\mathbf{I}),$$

那么二者的乘积关于 $\mathbf{x}$ 仍然正比于一个高斯分布：

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1, \sigma_1^2\mathbf{I})\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_2, \sigma_2^2\mathbf{I}) \propto \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \sigma^2\mathbf{I}).$$

其中精度，也就是方差倒数，满足：

$$\frac{1}{\sigma^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2},$$

均值满足：

$$\boldsymbol{\mu} = \sigma^2 \left(\frac{\boldsymbol{\mu}_1}{\sigma_1^2} + \frac{\boldsymbol{\mu}_2}{\sigma_2^2} \right).$$

后面推导 DDPM 的真实反向后验时，本质上就是在做高斯乘积。

3 正向扩散过程

3.1 一步加噪

DDPM 首先规定一个固定的正向扩散过程。这个过程不需要学习参数，它只是按照预设噪声强度逐步加入高斯噪声：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}).$$

其中 β_t 是第 t 步的噪声方差。定义：

$$\alpha_t = 1 - \beta_t.$$

于是一步加噪可以写为：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, (1 - \alpha_t) \mathbf{I}).$$

根据高斯重参数化，可写成：

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

这一步的含义是：保留 $\sqrt{\alpha_t}$ 倍的上一时刻信号，同时加入方差为 $1 - \alpha_t$ 的高斯噪声。

3.2 多步加噪的闭式公式

如果每次训练都从 $\mathbf{x}_0$ 一步步采样到 $\mathbf{x}_t$ ，会比较低效。DDPM 的关键性质是可以直接从 $\mathbf{x}_0$ 采样任意时刻 $\mathbf{x}_t$ 。

先看 $t = 1$ ：

$$\mathbf{x}_1 = \sqrt{\alpha_1} \mathbf{x}_0 + \sqrt{1 - \alpha_1} \boldsymbol{\epsilon}_1.$$

再看 $t = 2$ ：

$$\mathbf{x}_2 = \sqrt{\alpha_2} \mathbf{x}_1 + \sqrt{1 - \alpha_2} \boldsymbol{\epsilon}_2.$$

将 $\mathbf{x}_1$ 代入：

$$\mathbf{x}_2 = \sqrt{\alpha_2} (\sqrt{\alpha_1} \mathbf{x}_0 + \sqrt{1 - \alpha_1} \boldsymbol{\epsilon}_1) + \sqrt{1 - \alpha_2} \boldsymbol{\epsilon}_2.$$

整理得：

$$\mathbf{x}_2 = \sqrt{\alpha_1 \alpha_2} \mathbf{x}_0 + \sqrt{\alpha_2 (1 - \alpha_1)} \boldsymbol{\epsilon}_1 + \sqrt{1 - \alpha_2} \boldsymbol{\epsilon}_2.$$

后两项都是高斯噪声的线性组合，因此仍是高斯噪声。它们的总方差为：

$$\alpha_2 (1 - \alpha_1) + (1 - \alpha_2).$$

展开：

$$\alpha_2 - \alpha_1 \alpha_2 + 1 - \alpha_2 = 1 - \alpha_1 \alpha_2.$$

因此可以写成：

$$\mathbf{x}_2 = \sqrt{\alpha_1 \alpha_2} \mathbf{x}_0 + \sqrt{1 - \alpha_1 \alpha_2} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

由此可猜想，对于任意 t ，定义：

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s,$$

则：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

下面用归纳法证明。

假设对 $t-1$ 成立：

$$\mathbf{x}_{t-1} = \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_{t-1}} \boldsymbol{\epsilon}'.$$

根据一步加噪：

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_t.$$

代入归纳假设：

$$\mathbf{x}_t = \sqrt{\alpha_t \bar{\alpha}_{t-1}} \mathbf{x}_0 + \sqrt{\alpha_t (1 - \bar{\alpha}_{t-1})} \boldsymbol{\epsilon}' + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_t.$$

由于

$$\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1},$$

所以信号项为：

$$\sqrt{\bar{\alpha}_t} \mathbf{x}_0.$$

噪声项的总方差为：

$$\alpha_t (1 - \bar{\alpha}_{t-1}) + (1 - \alpha_t).$$

展开：

$$\alpha_t - \alpha_t \bar{\alpha}_{t-1} + 1 - \alpha_t = 1 - \alpha_t \bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t.$$

因此噪声项可以合并为：

$$\sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}.$$

于是：

$$\boxed{\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}}$$

其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

所以：

$$\boxed{q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I})}$$

这就是 DDPM 正向扩散的闭式公式。

4 反向过程为什么需要学习

正向过程 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 是人为设定的，因此我们知道如何把数据变成噪声。生成时我们想反过来，从噪声生成数据，即学习：

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t).$$

DDPM 假设反向转移也是高斯分布：

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)).$$

完整反向生成链为：

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t),$$

其中：

$$p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

问题在于：真实的

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t)$$

通常难以直接计算，因为它依赖整个数据分布。但是，如果额外给定原始数据 $\mathbf{x}_0$ ，则

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$$

可以解析求出。训练时我们正好知道 $\mathbf{x}_0$ ，因此可以用这个后验指导模型学习反向去噪。

5 真实反向后验的详细推导

5.1 从贝叶斯公式开始

我们要推导：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0).$$

根据条件贝叶斯公式：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}.$$

由于马尔可夫性质：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0) = q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

所以：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})q(\mathbf{x}_{t-1} | \mathbf{x}_0)}{q(\mathbf{x}_t | \mathbf{x}_0)}.$$

在这个式子中，分母 $q(\mathbf{x}_t | \mathbf{x}_0)$ 与变量 $\mathbf{x}_{t-1}$ 无关，因此如果只关心关于 $\mathbf{x}_{t-1}$ 的分布形状，可以写成：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \propto q(\mathbf{x}_t | \mathbf{x}_{t-1})q(\mathbf{x}_{t-1} | \mathbf{x}_0).$$

5.2 写出两个高斯项

第一项：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t}\mathbf{x}_{t-1}, \beta_t \mathbf{I}).$$

它是 $\mathbf{x}_t$ 关于均值 $\sqrt{\alpha_t}\mathbf{x}_{t-1}$ 的高斯。为了把它看成关于 $\mathbf{x}_{t-1}$ 的函数，写出指数部分：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) \propto \exp\left(-\frac{1}{2\beta_t} \|\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_{t-1}\|^2\right).$$

第二项由闭式公式得：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0, (1 - \bar{\alpha}_{t-1})\mathbf{I}).$$

其指数部分为：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_0) \propto \exp\left(-\frac{1}{2(1 - \bar{\alpha}_{t-1})} \|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0\|^2\right).$$

两者相乘后，指数部分相加：

$$\log q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = C - \frac{1}{2\beta_t} \|\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_{t-1}\|^2 - \frac{1}{2(1 - \bar{\alpha}_{t-1})} \|\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0\|^2,$$

其中 C 表示与 $\mathbf{x}_{t-1}$ 无关的常数。

5.3 配方求均值与方差

为了简化记号, 令:

$$\mathbf{y} = \mathbf{x}_{t-1}.$$

第一项展开:

$$\|\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{y}\|^2 = \mathbf{x}_t^\top \mathbf{x}_t - 2\sqrt{\alpha_t} \mathbf{x}_t^\top \mathbf{y} + \alpha_t \mathbf{y}^\top \mathbf{y}.$$

乘上 $1/(2\beta_t)$ 后, 与 $\mathbf{y}$ 有关的二次项和一次项为:

$$-\frac{\alpha_t}{2\beta_t} \mathbf{y}^\top \mathbf{y} + \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t^\top \mathbf{y}.$$

第二项展开:

$$\|\mathbf{y} - \sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0\|^2 = \mathbf{y}^\top \mathbf{y} - 2\sqrt{\bar{\alpha}_{t-1}} \mathbf{x}_0^\top \mathbf{y} + \bar{\alpha}_{t-1} \mathbf{x}_0^\top \mathbf{x}_0.$$

乘上 $1/[2(1 - \bar{\alpha}_{t-1})]$ 后, 与 $\mathbf{y}$ 有关的部分为:

$$-\frac{1}{2(1 - \bar{\alpha}_{t-1})} \mathbf{y}^\top \mathbf{y} + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0^\top \mathbf{y}.$$

把两部分加起来:

$$\log q(\mathbf{y} \mid \mathbf{x}_t, \mathbf{x}_0) = C - \frac{1}{2} \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{y}^\top \mathbf{y} + \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right)^\top \mathbf{y}.$$

高斯分布的标准指数形式为:

$$-\frac{1}{2\sigma^2} \mathbf{y}^\top \mathbf{y} + \frac{1}{\sigma^2} \boldsymbol{\mu}^\top \mathbf{y} + C.$$

对比可得后验方差满足:

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}}.$$

通分:

$$\frac{1}{\tilde{\beta}_t} = \frac{\alpha_t(1 - \bar{\alpha}_{t-1}) + \beta_t}{\beta_t(1 - \bar{\alpha}_{t-1})}.$$

因为 $\beta_t = 1 - \alpha_t$, 分子为:

$$\alpha_t(1 - \bar{\alpha}_{t-1}) + 1 - \alpha_t = \alpha_t - \alpha_t \bar{\alpha}_{t-1} + 1 - \alpha_t = 1 - \alpha_t \bar{\alpha}_{t-1}.$$

又因为:

$$\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1},$$

所以分子为:

$$1 - \bar{\alpha}_t.$$

因此:

$$\frac{1}{\tilde{\beta}_t} = \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})}.$$

于是:

$$\boxed{\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t}$$

再求均值。由标准形式:

$$\frac{1}{\tilde{\beta}_t} \tilde{\boldsymbol{\mu}}_t = \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0.$$

所以：

$$\tilde{\boldsymbol{\mu}}_t = \tilde{\beta}_t \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right).$$

将

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$

代入第一项：

$$\tilde{\beta}_t \frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t.$$

代入第二项：

$$\tilde{\beta}_t \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0.$$

因此：

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t$$

最终得到：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I})$$

这就是 DDPM 真实反向后验的详细推导。

6 从 $\mathbf{x}_0$ 参数化到噪声参数化

后验均值 $\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)$ 中包含 $\mathbf{x}_0$ 。但是生成时我们没有真实 $\mathbf{x}_0$ ，只有当前噪声样本 $\mathbf{x}_t$ 。因此需要神经网络估计相关信息。

由正向闭式公式：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}$$

可以解出：

$$\mathbf{x}_0 = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}}{\sqrt{\bar{\alpha}_t}}.$$

如果神经网络预测噪声：

$$\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \approx \boldsymbol{\epsilon},$$

那么可估计：

$$\hat{\mathbf{x}}_0 = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)}{\sqrt{\bar{\alpha}_t}}.$$

把这个 $\hat{\mathbf{x}}_0$ 代入后验均值公式，就可以得到模型均值。

原论文中常用的均值参数化为：

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right)$$

下面说明这个公式如何得到。

从真实后验均值开始：

$$\tilde{\boldsymbol{\mu}}_t = \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t.$$

代入：

$$\mathbf{x}_0 = \frac{\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}}{\sqrt{\bar{\alpha}_t}}.$$

注意：

$$\bar{\alpha}_t = \alpha_t \bar{\alpha}_{t-1}, \quad \sqrt{\bar{\alpha}_t} = \sqrt{\alpha_t} \sqrt{\bar{\alpha}_{t-1}}.$$

第一项变为：

$$\frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \cdot \frac{\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}}{\sqrt{\alpha_t}\sqrt{\bar{\alpha}_{t-1}}} = \frac{\beta_t}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)}\mathbf{x}_t - \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}.$$

第二项仍为：

$$\frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{x}_t.$$

因此 $\mathbf{x}_t$ 的系数为：

$$\frac{\beta_t}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)} + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}.$$

通分到同一个分母 $\sqrt{\alpha_t}(1-\bar{\alpha}_t)$ ：

$$\frac{\beta_t + \alpha_t(1-\bar{\alpha}_{t-1})}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)}.$$

分子：

$$\beta_t + \alpha_t(1-\bar{\alpha}_{t-1}) = 1 - \alpha_t + \alpha_t - \alpha_t \bar{\alpha}_{t-1} = 1 - \bar{\alpha}_t.$$

所以 $\mathbf{x}_t$ 的系数变为：

$$\frac{1-\bar{\alpha}_t}{\sqrt{\alpha_t}(1-\bar{\alpha}_t)} = \frac{1}{\sqrt{\alpha_t}}.$$

因此：

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}}\mathbf{x}_t - \frac{\beta_t}{\sqrt{\alpha_t}\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}.$$

提取 $1/\sqrt{\alpha_t}$ ：

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon} \right).$$

用神经网络预测的噪声替换真实噪声，得到：

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right)$$

7 变分下界的推导

7.1 最大似然目标

生成模型希望最大化数据似然：

$$\log p_\theta(\mathbf{x}_0).$$

但是由于模型包含隐变量 $\mathbf{x}_{1:T}$ ，有：

$$p_\theta(\mathbf{x}_0) = \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}.$$

这个积分通常难以直接计算，因此使用变分推断。

7.2 引入正向过程作为变分分布

注意：

$$\log p_\theta(\mathbf{x}_0) = \log \int p_\theta(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}.$$

乘除同一个正向过程：

$$\log p_\theta(\mathbf{x}_0) = \log \int q(\mathbf{x}_{1:T} | \mathbf{x}_0) \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} d\mathbf{x}_{1:T}.$$

这可以写成关于 q 的期望：

$$\log p_\theta(\mathbf{x}_0) = \log \mathbb{E}_{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \left[\frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

根据 Jensen 不等式：

$$\log \mathbb{E}[Y] \geq \mathbb{E}[\log Y].$$

因此：

$$\log p_\theta(\mathbf{x}_0) \geq \mathbb{E}_q \left[\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

右侧称为证据下界 (Evidence Lower Bound, ELBO)：

$$\text{ELBO} = \mathbb{E}_q \left[\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

最大化 ELBO 等价于最小化负 ELBO：

$$L = \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

7.3 展开联合分布

正向过程为：

$$q(\mathbf{x}_{1:T} | \mathbf{x}_0) = \prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1}).$$

反向生成过程为：

$$p_\theta(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t).$$

代入负 ELBO：

$$L = \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t=1}^T \log p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) + \sum_{t=1}^T \log q(\mathbf{x}_t | \mathbf{x}_{t-1}) \right].$$

经过整理，DDPM 论文将其写成若干项：

$$L = L_T + \sum_{t=2}^T L_{t-1} + L_0.$$

其中：

$$L_T = D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \| p(\mathbf{x}_T)),$$

$$L_{t-1} = D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)),$$

$$L_0 = -\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1).$$

这里最重要的是中间项 L_{t-1} 。它要求模型反向分布接近真实后验分布。换言之，模型学习去噪的数学目标是：

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) \approx q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0).$$

8 KL 散度如何变成均方误差

8.1 两个高斯分布的 KL 散度

如果有两个各向同性高斯分布：

$$q = \mathcal{N}(\boldsymbol{\mu}_q, \sigma_q^2 \mathbf{I}), \quad p = \mathcal{N}(\boldsymbol{\mu}_p, \sigma_p^2 \mathbf{I}),$$

则它们的 KL 散度为：

$$D_{\text{KL}}(q||p) = \frac{1}{2} \left[d \log \frac{\sigma_p^2}{\sigma_q^2} - d + \frac{d\sigma_q^2}{\sigma_p^2} + \frac{\|\boldsymbol{\mu}_p - \boldsymbol{\mu}_q\|^2}{\sigma_p^2} \right],$$

其中 d 是数据维度。

如果训练时把方差固定，或者让模型方差不参与主要优化，那么与参数 θ 有关的部分主要是均值差：

$$D_{\text{KL}}(q||p_\theta) \propto \|\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) - \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0)\|^2.$$

因此，优化 KL 散度可以转化为优化模型均值和真实后验均值之间的均方误差。

8.2 均值误差与噪声误差的关系

真实后验均值可写成：

$$\tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right).$$

模型均值写成：

$$\boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right).$$

两者相减：

$$\boldsymbol{\mu}_\theta - \tilde{\boldsymbol{\mu}}_t = \frac{1}{\sqrt{\alpha_t}} \left[-\frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_\theta + \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right].$$

整理：

$$\boldsymbol{\mu}_\theta - \tilde{\boldsymbol{\mu}}_t = \frac{\beta_t}{\sqrt{\alpha_t} \sqrt{1 - \bar{\alpha}_t}} (\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)).$$

因此：

$$\|\boldsymbol{\mu}_\theta - \tilde{\boldsymbol{\mu}}_t\|^2 = \frac{\beta_t^2}{\alpha_t(1 - \bar{\alpha}_t)} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2.$$

这说明，均值预测误差与噪声预测误差只差一个与 t 有关的权重系数。因此，优化噪声预测误差是合理的。

8.3 简化训练目标

DDPM 论文中常用的简化目标为：

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\epsilon}} \left[\left\| \boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t) \right\|^2 \right]$$

这里：

$$t \sim \text{Uniform}(\{1, \dots, T\}), \quad \mathbf{x}_0 \sim q(\mathbf{x}_0), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

这个目标的逻辑是：

1. 从真实数据中取 $\mathbf{x}_0$;
2. 随机选择时间步 t ;
3. 随机采样噪声 ϵ ;
4. 用闭式公式构造 $\mathbf{x}_t$;
5. 让神经网络根据 $\mathbf{x}_t$ 和 t 预测 ϵ 。

从数学上说，噪声预测目标是变分目标中 KL 项的一种重新参数化和简化加权形式。从直观上说，模型学会预测噪声，就等价于学会如何去噪。

9 采样公式推导

训练完成后，从：

$$\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

开始反向采样。

模型反向分布为：

$$p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}).$$

因此采样时：

$$\mathbf{x}_{t-1} = \boldsymbol{\mu}_{\theta}(\mathbf{x}_t, t) + \sigma_t \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

代入均值公式：

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$$

通常当 $t > 1$ 时采样 $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ ，当 $t = 1$ 时取 $\mathbf{z} = \mathbf{0}$ ，避免最后一步再加入随机噪声。

10 DDPM 数学结构的整体理解

DDPM 的数学结构可以总结为四个层次。

10.1 第一层：正向过程是人为设定的

正向过程：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

不是学习出来的，而是人为规定的。它的作用是构造一个从数据到噪声的路径。

10.2 第二层：闭式公式让训练高效

由于：

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}),$$

所以训练时不需要真的运行 t 次加噪，只需一次采样即可得到任意时间步的带噪样本。

10.3 第三层：后验分布提供反向学习目标

通过贝叶斯公式和高斯乘积，可以得到：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\tilde{\boldsymbol{\mu}}_t, \tilde{\boldsymbol{\beta}}_t \mathbf{I}).$$

这个分布告诉我们，如果知道原图 $\mathbf{x}_0$ ，从 $\mathbf{x}_t$ 回到 $\mathbf{x}_{t-1}$ 的理想反向步骤是什么。

10.4 第四层：噪声预测使目标简单稳定

由于 $\mathbf{x}_t$ 可以写成：

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon},$$

预测 $\boldsymbol{\epsilon}$ 就等价于预测 $\mathbf{x}_0$ ，也等价于确定反向均值。因此最终训练目标可以简化为：

$$\mathbb{E} [\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2].$$

11 常见疑问

11.1 为什么最终 $\mathbf{x}_T$ 接近高斯噪声？

因为：

$$\mathbf{x}_T = \sqrt{\bar{\alpha}_T} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_T} \boldsymbol{\epsilon}.$$

如果噪声调度让 $\bar{\alpha}_T$ 非常接近 0，则：

$$\sqrt{\bar{\alpha}_T} \mathbf{x}_0 \approx 0, \quad \sqrt{1 - \bar{\alpha}_T} \approx 1.$$

于是：

$$\mathbf{x}_T \approx \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}).$$

11.2 为什么模型要输入时间步 t ？

不同时间步的噪声强度不同。同一个 $\mathbf{x}_t$ 在不同 t 下代表不同程度的破坏，因此模型必须知道当前处于哪个去噪阶段。数学上，网络实际学习的是：

$$\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t),$$

而不是单纯的 $\boldsymbol{\epsilon}_\theta(\mathbf{x}_t)$ 。

11.3 为什么不用直接预测 $\mathbf{x}_0$ ？

直接预测 $\mathbf{x}_0$ 也是可行的，后续许多扩散模型也讨论了不同参数化方式。但 DDPM 原论文发现预测噪声 $\boldsymbol{\epsilon}$ 在实践中效果很好。其原因之一是训练目标形式简单，并且不同噪声级别下都可以构造清晰的监督信号。

12 结论

DDPM 的数学推导可以概括为以下主线：

1. 定义逐步加噪的马尔可夫过程；
2. 利用高斯线性性质推导出 $q(\mathbf{x}_t | \mathbf{x}_0)$ 的闭式公式；
3. 利用贝叶斯公式推导真实反向后验 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ ；
4. 用变分下界把最大似然训练转化为 KL 散度优化；
5. 利用高斯 KL 的性质，将反向均值学习转化为均方误差；
6. 通过噪声参数化，把训练目标简化为预测噪声。

最终，DDPM 的核心训练公式是：

$$L_{\text{simple}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2 \right],$$

核心采样公式是：

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}.$$

从直观角度看，DDPM 把图像生成转化为一系列小步去噪；从数学角度看，它通过高斯马尔可夫链、贝叶斯后验和变分推断建立了严格的概率模型。这正是 DDPM 既容易理解又具有强大生成能力的原因。